

데이터 전처리 계획서

로브 서비스 데이터 수집 계획

조라에몽의 만능 도구들

이창우, 전승권, 전종혁, 조동휘, 최수아

멘토 최민수

2026-05-30

Contents

1. 문서 개요	3
1.1 목적	3
1.2 전처리 원칙	3
2. 입력 데이터 범위	4
2.1 입력 데이터셋	4
2.2 기준 관계	5
3. 전처리 아키텍처	6
3.1 구성 방향	6
3.2 AWS 구성 요소	6
3.3 S3 경로 기준	7
4. 전처리 파이프라인	8
4.1 처리 흐름	9
4.2 단계별 처리 기준	10
5. 공통 정규화 규칙	11
5.1 식별자 규칙	11
5.2 명칭 정규화	11
5.3 주소와 행정구역 정규화	12
5.4 좌표 정규화	12
5.5 날짜와 기간 정규화	12
6. 데이터 유형별 전처리	13
6.1 City 전처리	13
6.2 Attraction 전처리	13
6.3 Festival 전처리	14
7. 품질 검증 및 검수 큐	15
7.1 자동 검증 기준	15
7.2 검수 큐 분류	16
7.3 신뢰도 점수	16
8. 파생 데이터 생성	17
8.1 추천용 파생 필드	17
8.2 RAG 및 검색용 데이터	17
9. DynamoDB 저장 및 적재 기준	18
9.1 저장 계층	18
9.2 DynamoDB 테이블 후보	18
9.3 Item 공통 속성	19
9.4 적재 조건	19
9.5 Lambda 적재 실패 처리	20
10. 운영 및 재처리 정책	21
11. 법적·운영 유의사항	22
12. 산출물	23

13. 본 문서 반영 이력

24

1. 문서 개요

1.1 목적

본 문서는 로브(Lovv)의 한국·일본 지역 추천 데이터가 수집된 이후 AWS S3에 원본을 적재하고 AWS Lambda로 전처리한 뒤 NoSQL 저장소인 Amazon DynamoDB에 서비스용 데이터를 적재하기 위한 원본 정제, 표준화, 품질 검증, 파생 데이터 생성, 적재 기준을 정의한다.

수집 계획서는 City, Attraction, Festival 데이터를 먼저 폭넓게 취득하고 이후 검증·보정하는 방향을 가진다.

본 전처리 계획서는 그 다음 단계에서 원본 데이터의 표현 차이와 누락·중복·최신성 문제를 정리하여 서비스 사용 가능한 데이터셋으로 변환하는 데 초점을 둔다.

1.2 전처리 원칙

- **Raw 보존:** API 응답, HTML 추출 결과, 수동 검수 입력값은 JSON 문서로 저장한 뒤 S3 Raw 영역에 보존한다.
- **Lambda 기반 배치 처리:** S3 Raw Bucket에 일정 기간 누적된 JSON 원본을 Lambda가 배치 단위로 읽어 전처리한다.
- **DynamoDB 적재:** 서비스 조회용 데이터는 Raw와 분리하여 DynamoDB 테이블에 정규화 문서 형태로 적재한다.
- **국가별 차이 흡수:** 한국 시·군·구와 일본 시·정·촌·구의 명칭, 행정구역, 날짜, 주소 표현 차이를 공통 스키마로 매핑한다.
- **상태 기반 처리:** 모든 필드는 collected, needs_review, missing, blocked 상태를 유지하고 전처리 결과에도 상태를 전파한다.
- **출처 추적:** 정규화 값은 source_name, source_url, collected_at, verified_at, data_confidence와 연결한다.
- **추천 사용성 우선:** 설명, 태그, 계절성, 좌표, 운영정보는 추천·일정 생성에 바로 사용할 수 있는 형태로 가공한다.

2. 입력 데이터 범위

2.1 입력 데이터셋

입력 구분	주요 내용	전처리 목적
City Raw	도시명, 행정구역, 좌표, 설명, 기후, 공식 사이트	지역 기준 엔티티 정규화
Attraction Raw	관광지명, 주소, 설명, 운영시간, 운영기간, 입장료, 좌표, 사진	일정 후보 데이터 정규화
Festival Raw	축제명, 개최지, 기간, 설명, 사진, 공식 링크	월별·계절성 추천 후보 정규화
Climate Raw	월별 평균 기온, 강수량, 계절 메모	여행 적합도와 계절 태그 생성
Statistics Raw	방문자 수, 관광 동향, 지역 통계	혼잡도·인지도 보조 지표 생성
Verification Raw	공식 사이트 확인값, 수동 검수 결과, 검수 메모	최신성·신뢰도 보정
Korea Local Validation	data/KR/prefectures.json, cities.json, attractions.json, festivals.json, visitor_statistics.json	S3 Raw 적재 전 한국 실제 수집 구조와 수량 검증

2.2 기준 관계

전처리 후에도 수집 계획서의 기본 관계를 유지한다.


```
text
City
├── Attraction
└── Festival
```

관계	전처리 기준
City 1:N Attraction	모든 관광지는 하나의 대표 City에 연결한다. 경계 지역은 주소와 좌표를 기준으로 대표 City를 결정하고 예외 메모를 남긴다.
City 1:N Festival	모든 축제는 개최 장소 기준 City에 연결한다. 광역 개최 축제는 주 개최지와 보조 개최지를 분리한다.

3. 전처리 아키텍처

3.1 구성 방향

수집 결과는 먼저 JSON 원본 파일로 직렬화해 S3 Raw Bucket에 적재한다. Raw 원본은 재사용과 재처리를 위해 일정 기간 Prefix 단위로 누적 보관하고, 보관 기간 또는 처리 기준이 충족되면 Lambda가 해당 원본 JSON 묶음을 읽어 정제·정규화·품질 검증·파생 필드 생성을 수행한 뒤 DynamoDB에 저장한다.



3.2 AWS 구성 요소

구성 요소	역할	저장/처리 단위
S3 Raw Bucket	수집 원본 누적 보존	국가, 출처, 엔티티 유형, 수집 일 기준 객체
S3 Processed Prefix	Lambda 처리 결과와 품질 리포트 보존	정규화 JSON, 실패 리포트, 검수 대상 목록
Lambda Preprocessor	일정 기간 누적된 Raw JSON 묶음의 스키마 검증, 필드 정제, 정규화, 중복 후보 탐지, DynamoDB 적재	S3 Prefix 또는 배치 묶음
DynamoDB	City, Attraction, Festival, 검수 상태, 품질 메타데이터 저장	엔티티 단위 Item
CloudWatch Logs	Lambda 실행 로그와 실패 원인 기록	실행 요청 단위
DLQ 또는 실패 Prefix	처리 실패 이벤트 격리	실패 S3 객체 또는 이벤트

3.3 S3 경로 기준

영역	예시 Prefix	내용
Raw	raw/{country}/{source}/{entity_type}/{yyyy}/{mm}/{dd}/	JSON으로 저장한 수집 원본 API 응답, HTML 추출값, 수동 입력 원본
Processed	processed/{country}/{entity_type}/{yyyy}/{mm}/{dd}/	Lambda 전처리 결과 JSON
Quality	quality/{country}/{entity_type}/{yyyy}/{mm}/{dd}/	품질 검증 리포트
Review	review/{queue_name}/{yyyy}/{mm}/{dd}/	수동 검수 대상 목록
Failed	failed/{country}/{source}/{entity_type}/{yyyy}/{mm}/{dd}/	처리 실패 원본과 실패 사유

4. 전처리 파이프라인

4.1 처리 흐름

text

S3 Raw 데이터 적재



Raw 보관 기간 / 배치 기준 확인



Lambda 배치 실행



스키마 검증



필드 정제



엔티티 정규화



중복 제거 및 병합



품질 점수 산정



파생 필드 생성



검수 대상 분류



DynamoDB 적재

4.2 단계별 처리 기준

단계	처리 내용	산출물
S3 Raw 데이터 적재	API 응답, HTML 추출값, 수동 입력값을 JSON 문서로 저장	S3 Raw Object
Raw 보관 기간 / 배치 기준 확인	일정 기간 또는 처리 기준만큼 누적된 Raw Prefix를 전처리 대상으로 확정	Batch Manifest
Lambda 배치 실행	확정된 S3 Prefix 또는 Manifest를 입력으로 전처리 함수 실행	Lambda Invocation
스키마 검증	필수 필드 존재 여부, 타입, 인코딩, 날짜 포맷 점검	schema_validation_result
필드 정제	공백, HTML 태그, 제어문자, 중복 문장, 깨진 URL 제거	cleaned_fields
엔티티 정규화	도시·관광지·축제명, 행정구역, 좌표, 날짜를 공통 포맷으로 변환	normalized_entities
중복 제거 및 병합	동일 대상의 다중 출처 데이터를 하나의 대표 엔티티로 병합	merged_entities
품질 점수 산정	출처 신뢰도, 최신성, 필드 충족률, 검수 여부를 점수화	data_confidence
파생 필드 생성	테마 태그, 월별 추천 태그, 검색 인덱스 텍스트 생성	feature_dataset
검수 대상 분류	누락·충돌·저작권 위험 항목을 검수 큐로 이동	review_queue
DynamoDB 적재	City, Attraction, Festival, 품질 메타데이터를 Item 단위로 저장	DynamoDB Item

5. 공통 정규화 규칙

5.1 식별자 규칙

대상	ID 형식	예시
한국 City	KR-{도_코드}-{CITY_EN}	KR-42-GANGNEUNG
일본 City	JP-{도도부현}-{도시명}	JP-ISHIKAWA-KANAZAWA
한국 Attraction	KR-{도_코드}-{CITY_EN}-ATT-{contentid}	KR-42-GANGNEUNG-ATT-126508
한국 Festival	KR-{도_코드}-{CITY_EN}-FES-{contentid}	KR-42-GANGNEUNG-FES-2762975
일본 Attraction/ Festival	{country_code}-{entity_type}-{source_or_hash}	JP-FEST-HASH-001

ID는 재처리 시에도 바뀌지 않아야 한다.
일본 ID가 없는 일본 공식 사이트·지자체 페이지 기반 데이터는 URL 정규화 해시를 보조 식별자로 사용한다.

5.2 명칭 정규화

구분	처리 기준
한국어명	불필요한 괄호 설명, 지역 홍보 문구, 축제 회차 표기를 분리한다.
일본어 원문명	한자·가나 표기를 원문 필드로 보존한다.
한국어 표기	일본 도시·관광지·축제는 서비스 표시용 한국어 표기를 별도 관리한다.
검색명	공백 제거, 소문자화, 특수문자 제거, 별칭을 포함한 검색 키를 생성한다.

5.3 주소와 행정구역 정규화

국가	처리 기준
한국	광역시·도, 시·군·구, 읍·면·동을 분리하고 행정구역 코드와 매핑한다.
일본	도도부현, 시·정·촌·구를 분리하고 e-Stat 또는 Statistical LOD 기준 코드와 매핑한다.
공통	주소가 없거나 모호한 경우 좌표, 공식 사이트 설명, 지도 링크를 보조 근거로 사용한다.

5.4 좌표 정규화

- 위도·경도는 WGS84 기준 decimal degree로 저장한다.
- 좌표 범위가 국가 영역을 벗어나면 needs_review로 분류한다.
- City 대표 좌표와 Attraction/Festival 좌표 간 거리가 과도하게 크면 City 매핑 오류 후보로 분류한다.
- 좌표가 없는 데이터는 주소 기반 지오코딩 후보로 분류하되, 자동 지오코딩 결과는 검수 전까지 낮은 신뢰도로 둔다.

5.5 날짜와 기간 정규화

입력 유형	정규화 필드
단일 날짜	start_date, end_date 동일 값
기간	start_date, end_date, period_text
매년 반복 축제	month, season, recurrence_rule, period_text
연도별 변동 축제	event_year, start_date, end_date, verified_at
불명확한 기간	period_text 보존 후 needs_review

6. 데이터 유형별 전처리

6.1 City 전처리

필드	처리 기준
city_name_ko	한국 도시명 또는 일본 도시의 한국어 표기를 표준명으로 저장
city_name_local	한국은 한국어명, 일본은 일본어 원문명을 저장
province_or_prefecture	국가별 행정구역 체계에 맞춰 표준화
prefecture_id	한국 강원·경북처럼 광역 단위가 별도 JSON에 있는 경우 상위 행정 단위 외래키로 보존
description	외부 원문을 그대로 저장하지 않고 내부 요약문으로 재작성
climate	Wikipedia 취득값과 한국 기상청 또는 일본기상청(JMA) 비교 결과를 월별 기온·강수·계절 메모 구조로 분리
climate_table	한국 Wikipedia 기후 표 wikitext 원본을 보존하고, 전처리 단계에서 climate 요약과 월별 추천 지표로 분리
site_url	공식 관광 사이트 또는 지자체 사이트 우선

6.2 Attraction 전처리

필드	처리 기준
name	홍보 문구, 괄호 부가 설명, 지역 접두어를 분리하고 대표명 저장
address	행정구역과 상세 주소를 분리하고 City와 매핑
description	요약문, 검색용 본문, RAG용 문단을 분리
opening_hours	원문 문자열과 구조화된 영업시간을 함께 저장
opening_period	계절 운영 여부, 휴무 정보, 기간 원문을 분리
admission_fee	무료, 유료, 변동, 확인 필요 상태를 구분
photo_url	사용 가능 조건이 불명확하면 서비스 노출 대상에서 제외

6.3 Festival 전처리

필드	처리 기준
name	개최 연도·회차·지역명을 대표명과 부가 정보로 분리
period	연도별 날짜와 반복 월 정보를 분리
address	개최 장소가 여러 곳이면 주 개최지와 보조 개최지로 분리
description	축제 성격, 계절성, 문화 요소를 요약 태그로 추출
photo_url	공식 이미지 또는 사용 가능 조건이 확인된 이미지만 노출 후보로 둔다

7. 품질 검증 및 검수 큐

7.1 자동 검증 기준

검증 항목	기준	실패 시 상태
필수 필드	ID, 이름, City 매핑, 출처 URL 존재	missing 또는 needs_review
City 매핑	Attraction/Festival이 하나의 City와 연결됨	needs_review
URL 유효성	HTTP 접근 가능 또는 공식 딥링크 보존 가능	needs_review
좌표 범위	국가별 좌표 범위 안에 존재	needs_review
날짜 포맷	ISO 날짜 또는 반복 규칙으로 변환 가능	needs_review
저작권	사진·설명 사용 조건 확인 가능	blocked 또는 needs_review
최신성	운영시간·입장료·축제 기간 확인일 존재	needs_review

7.2 검수 큐 분류

큐	대상	처리자
location_review	City 매핑 충돌, 좌표 이상치, 주소 누락	데이터 담당자
date_review	축제 기간 불명확, 연도별 일정 미확인	데이터 담당자
license_review	사진·설명문 사용 조건 불명확	기획/운영 담당자
content_review	설명 품질 낮음, 관광지 성격 모호	기획/운영 담당자
source_review	공식 출처 부재, 비공식 출처만 존재	데이터 담당자

7.3 신뢰도 점수

data_confidence는 다음 요소를 기준으로 산정한다.

요소	가중 기준
출처 공식성	공식 API·공식 관광 사이트·지자체 사이트를 높게 평가
최신성	verified_at이 최근일수록 높게 평가
필드 충족률	필수 필드와 추천 핵심 필드가 채워질수록 높게 평가
출처 일치도	다중 출처 값이 일치할수록 높게 평가
수동 검수	검수 완료 항목을 높게 평가

8. 파생 데이터 생성

8.1 추천용 파생 필드

파생 필드	설명
theme_tags	자연, 음식, 역사, 문화, 휴식, 액티비티 등 추천 테마
season_tags	봄, 여름, 가을, 겨울, 우천 적합, 실내 중심 등 계절 태그
visit_months	추천 가능한 월 목록
crowding_score	방문자 수, 통계, 대도시 편중도 기반 혼잡 보조 점수
novelty_score	대도시 대비 덜 알려진 지역 추천을 위한 인지도 보조 점수
itinerary_fit	반나절, 1일, 1박 2일 일정 구성 적합도

8.2 RAG 및 검색용 데이터

산출물	구성
City 검색 문서	도시 요약, 행정구역, 계절성, 대표 관광지·축제 목록
Attraction 검색 문서	관광지 요약, 테마, 운영정보, 위치, 공식 링크
Festival 검색 문서	축제 요약, 개최 월, 지역, 공식 링크, 최신성 상태
검색 키	표준명, 원문명, 별칭, 지역명, 테마 키워드

RAG 문서는 외부 원문을 그대로 복제하지 않고 내부 요약문과 출처 링크 중심으로 구성한다.

9. DynamoDB 저장 및 적재 기준

9.1 저장 계층

계층	저장 내용	용도
S3 Raw Bucket	원본 응답, 추출 원문, 수집 메타데이터	재처리·감사·오류 추적
DynamoDB Normalized Tables	City, Attraction, Festival, 검수 상태	서비스 조회
Search Index	검색 문서, 임베딩 대상 텍스트, 키워드	RAG·검색
DynamoDB Review Table	검수 큐, 검수 결과, 승인·반려 이력	운영 관리

9.2 DynamoDB 테이블 후보

테이블	Partition Key	Sort Key	저장 내용
LovvCity	country_code	city_id	국가별 City 정규화 데이터
LovvAttraction	city_id	attraction_id	City에 속한 Attraction 정규화 데이터
LovvFestival	city_id	festival_id	City에 속한 Festival 정규화 데이터
LovvDataQuality	entity_id	checked_at	품질 검증 결과, 신뢰도, 실패 사유
LovvReviewQueue	queue_name	entity_id	수동 검수 대상과 처리 상태

9.3 Item 공통 속성

속성	설명
entity_id	City, Attraction, Festival의 안정 식별자
entity_type	city, attraction, festival
country_code	KR 또는 JP
source_name	원본 출처명
source_url	원본 또는 공식 확인 URL
s3_raw_uri	재처리를 위한 S3 Raw 객체 경로
normalized_payload	서비스 조회용 정규화 데이터
quality_status	collected, needs_review, missing, blocked
data_confidence	출처, 최신성, 필드 충족률 기반 신뢰도
collected_at	원본 수집 시각
processed_at	Lambda 처리 시각
verified_at	공식 확인 또는 수동 검수 시각

9.4 적재 조건

대상	최소 적재 조건
City	표준 ID, 도시명, 국가, 행정구역, 출처 URL
Attraction	표준 ID, 이름, City 매핑, 출처 URL, 주소 또는 좌표
Festival	표준 ID, 이름, City 매핑, 기간 원문 또는 개최 월, 출처 URL
검색 문서	내부 요약문, 출처 링크, 최신성 상태
서비스 노출	필수 필드 충족, 저작권 위험 없음, blocked 아님

9.5 Lambda 적재 실패 처리

실패 유형	처리
스키마 오류	DynamoDB에 적재하지 않고 S3 failed/ Prefix와 품질 리포트에 사유 기록
필수 필드 누락	LovvReviewQueue에 검수 대상으로 등록
DynamoDB 조건부 쓰기 실패	기존 Item과 충돌 여부를 확인하고 변경 이력 후보로 분류
Lambda 타임아웃	처리 단위를 더 작은 S3 객체 또는 배치로 나누어 재시도
일시적 AWS 오류	재시도 후 실패 이벤트를 DLQ 또는 실패 Prefix에 보존

10. 운영 및 재처리 정책

항목	정책
재처리 주기	City 기본 정보는 정기 배치, 운영시간·입장료·축제 기간은 최신성 상태에 따라 우선 재처리
부분 재처리	특정 S3 Prefix, 특정 출처, 특정 국가, 특정 City 단위로 Lambda 재실행 가능해야 함
Raw 보관 기간	원본 JSON은 재사용 가능한 기간 동안 S3 Raw Bucket에 보관하고, 보관 기간 만료 후에는 보존 정책에 따라 Glacier 전환 또는 삭제를 검토
배치 전처리 기준	보관 기간 경과, Prefix 단위 수집 완료, 수동 검수 마감 등 운영 기준 중 하나가 충족되면 Lambda 전처리를 실행
변경 감지	동일 원본 ID의 핵심 필드가 바뀌면 DynamoDB 변경 이력 후보를 남김
롤백	DynamoDB 적재 실패 시 기존 승인 Item을 유지하고 신규 결과는 실패 Prefix에 격리
감사 추적	S3 Raw URI, Lambda 실행 시각, Web Search Worker 확인, 수동 검수 결과를 모두 이력화

11. 법적·운영 유의사항

- Wikipedia 기반 설명은 출처와 원문 링크를 남기되 서비스 본문에는 내부 요약문을 사용한다.
- TourAPI, JNTO, JTA, 지자체 관광 사이트의 이용 조건과 출처 표기 조건을 보존한다.
- 사진은 사용 가능 조건이 확인된 경우에만 서비스 노출 후보로 둔다.
- 상업 플랫폼의 숙박·맛집 데이터는 직접 저장하지 않고 검색 딥링크 또는 사용자 이동 경로로 처리한다.
- 운영시간, 입장료, 축제 기간은 변경 가능성이 높으므로 서비스 응답에는 확인일 기준 문구를 연결한다.

12. 산출물

산출물	설명
city_normalized	국가별 도시 표준 엔티티
attraction_normalized	City와 연결된 관광지 표준 엔티티
festival_normalized	City와 연결된 축제 표준 엔티티
data_quality_report	누락, 충돌, 최신성, 저작권 위험 리포트
review_queue	수동 검수 대상 목록
rag_documents	추천 Agent와 검색용 내부 요약 문서
feature_dataset	테마, 계절성, 혼잡도, 일정 적합도 파생 필드
s3_raw_manifest	DynamoDB Item과 연결되는 S3 Raw 객체 목록
lambda_processing_log	Lambda 실행 결과, 실패 사유, 재처리 대상 기록

13. 본 문서 반영 이력

버전	날짜	작성자	변경 내용
v0.1	2026-06-03	LLM 파 트	데이터 수집 계획서를 기반으로 전처리 계획서 초안 작성
v0.2	2026-06-03	LLM 파 트	S3 Raw 적재, Lambda 전처리, DynamoDB 적재 아키텍처 반영
v0.3	2026-06-06	LLM 파 트	S3 Raw 누적 보관 후 Lambda 배치 전처리 및 DynamoDB 적재 흐름 반영
v0.4	2026-06-06	LLM 파 트	한국 강원·경북 실제 수집 산출물, KR-{도_코드}-{CITY_EN}ID 형식, climate_table 전처리 기준 반영