

일본 데이터 취득 계획서

로브 서비스 일본 데이터 취득 계획

조라에몽의 만능 도구들

이창우, 전승권, 전종혁, 조동휘, 최수아

멘토 최민수

2026-05-30

Contents

1. 목적	2
2. 목표 데이터 모델	3
2.1 관계 구조	3
2.2 City 데이터	3
2.3 Attraction 데이터	4
2.4 Festival 데이터	4
3. 데이터 소스 전략	6
3.1 Wikipedia	6
3.2 JNTO 관광 데이터	6
3.3 JTA 관광 DB	7
3.4 일본 정부 통계 및 JNTO Statistics	7
3.5 보조 공식·공공 출처	8
4. 전체 취득 범위	9
4.1 전체 수집 대상	10
4.2 취득 상태 관리	11
4.3 공식 확인 우선순위	12
5. 수집 전략	13
5.1 자동 수집 전략	13
5.2 공식 확인 및 검수 전략	13
5.3 데이터 정규화 규칙	14
6. 단일 취득 파이프라인	15
6.1 처리 흐름	15
6.2 Web Search Worker 적용 조건	16
7. 저장 구조	17
7.1 핵심 테이블	17
7.2 City 예시	17
7.3 Attraction 예시	18
7.4 Festival 예시	18
8. 품질 검증 기준	19
9. 법적·운영 제약	20
10. 본 문서 반영 계획	21
11. 참고 출처	22
12. 변경 이력	23

1. 목적


본 문서는 여행 추천 Multi-Agent 서비스에서 일본 소도시 추천에 필요한 도시·관광지·축제 데이터를 한 번에 취득하기 위한 범위, 데이터 소스, 검증 방식, 저장 구조를 정의한다.

이번 초안의 핵심은 다음과 같다.

- City, Attraction, Festival의 정의된 항목을 모두 수집 대상으로 둔다.
- 도도부현의 간략 정보와 산하 도시 목록을 먼저 취득하고, 산하 도시 목록에 포함된 City 만 Wikipedia 문서 크롤링 대상으로 둔다.
- 취득 결과는 JSON 문서로 저장한 뒤 S3 Raw Bucket에 적재한다.
- 운영시간, 운영기간, 입장료, 사진처럼 출처별 표현 차이가 큰 항목도 최초 취득 범위에 포함한다.
- 자동 수집, 공식 사이트 확인, Web Search Worker, 수동 검수를 하나의 취득 파이프라인으로 묶어 처리한다.
- 추천 DB는 City 1:N Attraction, City 1:N Festival 관계를 기준으로 설계한다.

2. 목표 데이터 모델

2.1 관계 구조



관계	설명
City 1:N Attraction	하나의 일본 도시는 여러 관광지를 가진다.
City 1:N Festival	하나의 일본 도시는 여러 축제·행사를 가진다.

2.2 City 데이터

City는 추천의 기준 지역이다.

일본 목적지는 시·정·촌·구 단위의 소도시를 기본 단위로 관리한다.

도도부현 문서에서는 간략 정보와 산하 도시 목록만 취득하고, 상세 정보 크롤링은 이 산하 도시 목록에 포함된 City만 대상으로 한다.

필드	수집 방식	수집 상태	설명
city_id	내부 생성	전부 수집	시스템 내부 지역 식별자
city_name_ko	도도부현 산하 도시 목록 / Wikipedia 크롤링 / 수동 정규화	전부 수집	한국어 도시명
city_name_ja	도도부현 산하 도시 목록 / Wikipedia 크롤링 / Wikidata	전부 수집	일본어 원문 도시명
prefecture	도도부현 간략 정보 / 행정구역 데이터	전부 수집	도도부현
location	산하 도시 Wikipedia 크롤링 / Wikidata	전부 수집	위치 정보, 좌표 또는 행정 위치
latitude	산하 도시 Wikipedia 크롤링 / Wikidata	전부 수집	대표 위도
longitude	산하 도시 Wikipedia 크롤링 / Wikidata	전부 수집	대표 경도
description	산하 도시 Wikipedia 크롤링 기반 요약	전부 수집	도시 역사·문화·특징 설명
climate	Wikipedia 취득 후 일본기상청(JMA) 자료와 비교	전부 수집	기후 개요 또는 월별 기후 메모
site_url	Wikipedia 외부 링크 / 공식 관광 사이트	전부 수집	도시 또는 관광 공식 사이트

2.3 Attraction 데이터

Attraction은 도시와 1:N 관계를 가지며, 일정 카드와 추천 결과 상세 화면의 핵심 소재로 사용한다.

필드	수집 방식	수집 상태	설명
attraction_id	내부 생성	전부 수집	관광지 식별자
city_id	City 매핑	전부 수집	소속 도시
name	JNTO / JTA	전부 수집	관광지명
address	JNTO / JTA / 공식 사이트	전부 수집	주소
description	JNTO / JTA 기반 요약	전부 수집	관광지 설명
site_url	JNTO / JTA / 공식 사이트	전부 수집	공식 또는 안내 페이지
opening_hours	공식 사이트 / 검수	전부 수집	운영시간
opening_period	공식 사이트 / 검수	전부 수집	계절 운영기간
latitude	JNTO / Wikidata / 지도 보조	전부 수집	위도
longitude	JNTO / Wikidata / 지도 보조	전부 수집	경도
admission_fee	공식 사이트 / 검수	전부 수집	입장료
photo_url	JNTO / 공식 사이트 / 검수	전부 수집	대표 사진 URL

2.4 Festival 데이터

Festival은 도시와 1:N 관계를 가지며, 월별 추천과 계절성 추천의 주요 근거로 사용한다.

필드	수집 방식	수집 상태	설명
festival_id	내부 생성	전부 수집	축제 식별자
city_id	City 매핑	전부 수집	개최 도시
name	JNTO / JTA	전부 수집	축제명
address	JNTO / JTA / 공식 사이트	전부 수집	개최 장소 주소
period	JNTO / JTA / 공식 사이트	전부 수집	개최 기간 또는 개최 월
description	JNTO / JTA 기반 요약	전부 수집	축제 설명
site_url	JNTO / JTA / 공식 사이트	전부 수집	공식 또는 안내 페이지
photo_url	JNTO / 공식 사이트 / 검수	전부 수집	대표 사진 URL

3. 데이터 소스 전략

3.1 Wikipedia

항목	내용
주 용도	도도부현 간략 정보, 산하 도시 목록, 산하 도시 위치 정보와 역사·문화 개요
취득 대상	도도부현 이름, 도도부현 간략 설명, 산하 도시 목록, 산하 도시명, 위치, 설명, 기후, 사이트 링크
장점	도도부현 단위에서 크롤링 대상 City 목록을 먼저 확정하고, 산하 도시 단위 설명과 위치 정보를 체계적으로 취득할 수 있다.
한계	관광지·축제 상세 정보는 불완전할 수 있고, 설명문 사용 시 라이선스 표기가 필요하다.
적용 방식	Wikipedia API 또는 도도부현 문서에서 간략 정보와 산하 도시 목록을 우선 확보하고, 산하 도시 목록에 포함된 City 문서만 Wikipedia 크롤링 대상으로 삼아 설명·위치·외부 링크·기후를 추출한다.

3.2 JNTO 관광 데이터

항목	내용
주 용도	관광지 정보, 축제 정보
취득 대상	관광지명, 주소, 설명, 사이트 링크, 축제명, 기간, 축제 설명
장점	일본 공식 관광 데이터로 신뢰도가 높고, 관광지·축제 정보 품질이 좋다.
한계	운영시간, 입장료, 사진은 항목별 누락 가능성이 있다.
적용 방식	Attraction과 Festival 자동 수집의 1차 소스로 사용한다.

3.3 JTA 관광 DB

항목	내용
주 용도	관광지 상세 설명, 축제 상세 설명
취득 대상	관광지 설명, 문화 정보, 지역 특산품, 축제 설명
장점	설명 데이터 품질이 높고 전국 단위 보강에 적합하다.
한계	실제 제공 데이터 구조와 이용 조건 확인이 필요하다.
적용 방식	JNTO 데이터의 설명 보강 소스로 사용한다.

3.4 일본 정부 통계 및 JNTO Statistics

항목	내용
주 용도	통계 데이터
취득 대상	방문객 수, 관광 통계, 지역별 통계
장점	추천 품질 향상과 혼잡도·수요 분석에 활용할 수 있다.
한계	추천 점수에 바로 반영하려면 지표 해석 기준을 추가로 정의해야 한다.
적용 방식	지역별 방문객 수와 관광 통계를 함께 수집하고 City 기준 보조 지표로 연결한다.

3.5 보조 공식·공공 출처

출처	사용 목적	적용 방식
e-Stat / Statistical LOD	행정구역 코드, 지역 통계, 시정촌 메타데이터	City 정규화와 통계 보강
국토교통성 국토수치정보	좌표, 행정구역, 철도역·교통 데이터	위치·접근성 데이터 취득
일본기상청(JMA)	월별 기후·관측 데이터	Wikipedia에서 취득한 City climate 비교 검증
도도부현·시정촌 공식 관광 사이트	운영시간, 입장료, 최신 축제 일정 확인	누락·최신성 확인

4. 전체 취득 범위

4.1 전체 수집 대상

아래 항목은 모두 최초 취득 대상으로 둔다.

자동 수집에서 누락되거나 신뢰도가 낮은 것은 제외하지 않고 공식 사이트 확인, Web Search Worker, 수동 검수로 이어서 채운다.

구분	수집 항목	주요 출처	누락 시 처리
도시	도도부현 간략 정보, 산하 도시 목록, 도시명, 위치, 설명, 기후, 사이트 링크, 위도, 경도	Wikipedia API, Wikipedia 크롤링, Wikidata, JMA 비교 자료	
관광지	관광지명, 운영시간, 운영기간, 주소, 위도, 경도, 설명, 입장료, 사이트 링크, 사진	JNTO, JTA, 공식 사이트, Wikidata	
축제	축제명, 주소, 기간, 설명, 사진, 사이트 링크	JNTO, JTA, 공식 사이트	

4.2 취득 상태 관리

취득 상태	기준	처리 방식
collected	자동 수집 값이 있고 출처가 명확함	DB 적재
needs_ review	값은 있으나 표현이 모호하거나 최신성 확인이 필요함	수동 검수
missing	자동 수집에서 값을 찾지 못함	Web Search 또는 수동 입력 대상
blocked	약관·저작권·접근 제한으로 수집 불가	딥링크 또는 빈 값으로 대체 하고 사유 기록

4.3 공식 확인 우선순위

항목	확인 우선순위	사유
운영시간	높음	사용자 질문 빈도가 높고 일정 구성에 직접 영향을 준다.
운영기간	높음	계절 운영, 휴관일, 임시 중단 등 예외가 많다.
입장료	중간	무료·유료·계절 요금·패키지 요금이 혼재한다.
사진	중간	저작권과 외부 핫링크 문제가 있어 검증이 필요하다.
위도·경도	높음	지도 표시와 동선 계산에 필요하다.

공식 사이트 또는 수동 검수로 확인한 값에는 `verified_at`, `verified_source_url`, `verification_note`를 함께 기록한다.

5. 수집 전략

5.1 자동 수집 전략

대상	자동 수집 소스	처리 방식
도시	Wikipedia API, Wikipedia 크롤링, Wikidata, JMA	도도부현 간략 정보와 산하 도시 목록을 먼저 추출하고, 산하 도시 목록에 포함된 City 문서만 크롤링해 설명·위치·외부 링크·기후를 추출한다. 기후는 일본기상청(JMA) 자료와 비교한 뒤 City 테이블로 정규화한다.
관광지	JNTO, JTA, 공식 사이트, Wikidata	관광지명, 운영시간, 운영기간, 주소, 위도, 경도, 설명, 입장료, 사이트 링크, 사진을 추출하고 City와 매핑한다.
축제	JNTO, JTA, 공식 사이트	축제명, 주소, 기간, 설명, 사진, 사이트 링크를 추출하고 City와 매핑한다.
통계	JNTO Statistics, e-Stat, RESAS	방문객 수, 관광 통계, 지역별 지표를 수집하고 City 기준 보조 지표로 연결한다.

5.2 공식 확인 및 검수 전략

공식 확인과 검수는 자동 수집에서 실패했거나 검수 필요 상태로 분류된 항목에 적용한다. 이 과정은 별도 단계가 아니라 같은 취득 파이프라인의 후속 처리로 본다.


확인 항목	입력 기준
운영시간	공식 사이트에 명시된 최신 운영시간만 입력
운영기간	계절 운영 또는 축제 기간이 명확한 경우 입력
입장료	공식 사이트 또는 공공 관광 페이지에 있는 금액만 입력
사진	사용 가능 조건이 명확한 공식 이미지 또는 내부 제작 이미지 사용

5.3 데이터 정규화 규칙

- 도시명은 city_name_ja, city_name_ko, city_name_en을 분리 저장한다.
- 도도부현 간략 정보와 산하 도시 목록의 Wikipedia API 응답 또는 HTML 원본, 산하 도시 Wikipedia HTML 크롤링 원본을 Raw 데이터로 보존한다.
- 관광지와 축제는 반드시 city_id를 가진다.
- 기간 정보는 원문 문자열(period_text)과 정규화 값(start_date, end_date, month)을 함께 저장한다.
- 운영시간과 입장료는 최신성이 낮을 수 있으므로 data_confidence를 별도 기록한다.
- 외부 설명문은 원문 복제가 아니라 내부 요약문으로 재작성한다.

6. 단일 취득 파이프라인

6.1 처리 흐름



정의된 모든 필드가 JSON 원본으로 저장되도록 시도하는 것이 목표다.

수집 결과는 엔티티 유형과 출처별 JSON 문서로 직렬화한 뒤 S3 Raw Bucket에 먼저 적재한다.

Raw 원본은 재사용과 재처리를 위해 일정 기간 누적 보관하고, 보관 기간 또는 배치 기준이 충족되면 Lambda가 전처리한 뒤 DynamoDB에 적재한다.

운영시간·입장료·사진도 최초 수집 대상에 포함하며, 자동 수집 실패 시 `missing` 또는 `needs_review` 상태로 남기고 같은 파이프라인 안에서 공식 확인 또는 수동 검수로 채운다.

예시:

```

text
사용자 질문: 도쿄타워 운영시간 알려줘

1. DB에서 도쿄타워 Attraction 조회
2. opening_hours가 없거나 오래된 값이면 Web Search Worker 실행
3. 공식 사이트 또는 공식 관광 페이지 확인
4. 운영시간과 확인 출처를 함께 반환
  
```


6.2 Web Search Worker 적용 조건

조건	처리
DB에 정보 없음	공식 사이트 검색
운영시간·입장료 값이 오래됨	공식 사이트 재확인
축제 기간이 연도별로 바뀜	해당 연도 공식 페이지 확인
공식 출처가 아닌 블로그·SNS만 존재	답변 근거로 사용하지 않거나 낮은 신뢰도로 표시

7. 저장 구조

7.1 핵심 테이블

```

text
City
Attraction
Festival
S3 Raw Bucket

```

수집 원본은 DB에 바로 쓰지 않고 JSON 파일로 저장한 뒤 S3 Raw Bucket에 적재한다. S3 객체는 국가, 출처, 엔티티 유형, 수집일 기준 Prefix로 구분한다. 일정 기간 누적된 Raw Prefix는 Lambda 배치 전처리의 입력으로 재사용하며, 전처리 결과만 DynamoDB에 정규화 Item으로 적재한다.

7.2 City 예시

필드	예시
city_id	JP-ISHIKAWA-KANAZAWA
city_name_ko	가나자와
city_name_ja	Kanazawa市
prefecture	石川県
description	전통 정원, 금박 공예, 성하마을 문화가 남아 있는 이시카와현의 대표 소도시
climate	겨울 강설량이 많고 여름은 습도가 높다. 봄·가을 관광 적합도가 높다.
site_url	공식 관광 사이트 URL

7.3 Attraction 예시

필드	예시
name	兼六園
city_id	JP-ISHIKAWA-KANAZAWA
address	石川県Kanazawa市兼六町
description	일본 3대 정원 중 하나로 계절별 경관이 강한 관광지
opening_hours	공식 사이트 확인값
admission_fee	공식 사이트 확인값
site_url	공식 사이트 URL

7.4 Festival 예시

필드	예시
name	Kanazawa百万石まつり
city_id	JP-ISHIKAWA-KANAZAWA
address	石川県Kanazawa市 중심부
period	매년 6월
description	가나자와의 역사와 마에다 가문 문화를 기념하는 대표 축제
photo_url	공식 또는 사용 가능 조건이 확인된 이미지 URL

8. 품질 검증 기준

검증 항목	기준
City 매핑	모든 Attraction과 Festival은 하나의 City에 연결되어야 한다.
출처 기록	모든 자동 수집 데이터는 source_name, source_url, collected_at을 가진다.
전체 필드 상태	정의된 모든 필드는 collected, needs_review, missing, blocked 중 하나의 상태를 가진다.
최신성	운영시간, 운영기간, 입장료는 확인일을 기록한다.
기후 정합성	Wikipedia에서 취득한 City climate를 일본기상청(JMA) 자료와 비교하고 불일치 여부를 검수 메타데이터로 남긴다.
저작권	사진과 설명문은 사용 가능 조건을 확인한다. 설명문은 내부 요약문으로 저장한다.
공식성	자동 수집과 Web Search Worker는 공식 사이트 또는 공공 관광 페이지를 우선한다.

9. 법적·운영 제약

- Wikipedia 기반 설명은 라이선스 조건에 따라 출처와 원문 링크를 기록한다.
- JNTO, JTA, 지자체 관광 페이지는 이용약관과 크롤링 허용 범위를 확인한다.
- 사진은 저작권 위험이 크므로 자동 수집 값이 있더라도 사용 가능 조건을 확인하고, 불명확하면 `needs_review` 또는 `blocked`로 관리한다.
- 상업 플랫폼의 숙박·맛집 데이터는 직접 저장보다 딥링크 제공을 우선한다.
- 운영시간과 입장료는 변경 가능성이 높으므로 "확인일 기준" 문구를 서비스에 표시한다.

10. 본 문서 반영 계획

이 초안이 확정되면 다음 순서로 본 문서와 HTML에 반영한다.

- 04_data_collect_plan.md의 2.2 수집 데이터 정보 및 분량을 City, Attraction, Festival 관계 기준으로 보강한다.
- 2.4.2 일본 데이터 출처에 Wikipedia, JNTO, JTA, JNTO Statistics의 역할을 표로 반영한다.
- 3. 데이터 전처리 방식 및 인프라 구성에 자동 수집, 공식 확인, Web Search Worker, 검수 흐름을 추가한다.
- 4. 데이터 품질 정합성 관리 방법에 City 매핑, 출처 기록, 최신성 검증을 추가한다.
- 6. 수집 정책 및 제외 범위에 전체 필드 일괄 취득 원칙과 최신성 재확인 정책을 추가한다.
- scripts/generate_pages.py를 실행하여 pages/04_data_collect_plan.html에 반영한다.

11. 참고 출처

- Wikipedia: <https://www.wikipedia.org/>
- JNTO: <https://www.jnto.go.jp/>
- Japan Tourism Statistics: <https://statistics.jnto.go.jp/en/>
- e-Stat API: <https://www.e-stat.go.jp/api/>
- Statistical LOD Area Data: <https://data.e-stat.go.jp/lodw/index.php/en/provdata/lodRegion>
- 국토교통성 국토수치정보: <https://nlftp.mlit.go.jp/ksj/>
- 일본기상청 기후 데이터: <https://www.data.jma.go.jp/stats/data/en/index.html>

12. 변경 이력

버전	날짜	작성자	변경 내용
v0.1	2026-06-02	LLM 파트	일본 데이터 취득 계획서 초안 작성
v0.2	2026-06-02	LLM 파트	데이터 모델, 자동 수집·검수 범위, Web Search Worker 확인 전략 구체화
v0.3	2026-06-02	LLM 파트	정의 필드를 모두 수집하고 누락 항목은 취득 상태로 관리하는 방향 반영
v0.4	2026-06-02	LLM 파트	단계 경계를 제거하고 도도부현 간략 정보와 산하 도시 목록 기반 City 크롤링, JSON 원본의 S3 저장, 기후 데이터 비교 검증 방식으로 재정리