

일본 데이터 취득 계획서

로브 서비스 데이터 수집 계획

조라에몽의 만능 도구들

이창우, 전승권, 전종혁, 조동휘, 최수아

멘토 최민수

2026-06-03

Contents

1. 문서 개요	2
1.1 목적	2
1.2 문서 관리표	2
1.3 데이터 수집 매트릭스	3
1.4 운영 및 검증 체크리스트	4
2. 목표 데이터 모델	5
2.1 관계 구조	5
2.2 City 데이터	5
2.3 Attraction 데이터	6
2.4 Festival 데이터	6
3. 데이터 소스 전략	7
3.1 Wikipedia	7
3.2 JNTO 관광 데이터	7
3.3 JTA 관광 DB	7
3.4 일본 정부 통계 및 JNTO Statistics	8
3.5 보조 공식·공공 출처	8
4. 전체 취득 범위	9
4.1 전체 수집 대상	9
4.2 취득 상태 관리	10
4.3 공식 확인 우선순위	11
5. 수집 전략	12
5.1 자동 수집 전략	12
5.2 공식 확인 및 검수 전략	12
5.3 데이터 정규화 규칙	12
6. 단일 취득 파이프라인	13
6.1 처리 흐름	13
6.2 Web Search Worker 적용 조건	13
7. 저장 구조	14
7.1 JSON 파일 구성	14
7.2 JSON 구조 예시	14
7.3 저장 원칙	14
8. 품질 검증 기준	15
9. 법적·운영 제약	15
10. 데이터 취득 결과서 작성 계획	15
11. 참고 출처	16
12. 변경 이력	16

1. 문서 개요

1.1 목적

본 문서는 여행 추천 Multi-Agent 서비스에서 일본 소도시 추천에 필요한 도시·관광지·축제 데이터를 한 번에 취득하기 위한 범위, 데이터 소스, 검증 방식, 저장 구조를 정의한다. 이번 초안의 핵심은 다음과 같다.

- City, Attraction, Festival의 정의된 항목을 모두 수집 대상으로 둔다.
- 운영시간, 운영기간, 입장료, 사진처럼 출처별 표현 차이가 큰 항목도 최초 취득 범위에 포함한다.
- 자동 수집, 공식 사이트 확인, Web Search Worker, 수동 검수를 하나의 취득 파이프라인으로 묶어 처리한다.
- 일본 데이터는 City 기준 JSON 파일 안에 Attraction과 Festival 배열을 포함하는 구조로 저장한다.

1.2 문서 관리표

항목	내용
문서명	일본 데이터 취득 계획서
문서 버전	v0.5
문서 상태	본 문서 반영 전 초안
작성일	2026-06-02
개정일	2026-06-03
작성 주체	로브 기획팀
적용 범위	일본 소도시 City, Attraction, Festival 데이터 취득 및 검증
기준 산출물	docs/ 04_data_collect_plan/ japan_data_acquisition_plan.md
후속 반영 대상	데이터 취득 결과서

1.3 데이터 수집 매트릭스

대상	수집 범위 및 방식	주요 출처 및 검증
City	추천 기준 지역. 시·정·촌·구 단위 소 도시를 하나의 추천 단위로 관리하고, 행정구역과 대표 좌표를 기준으로 정규화한다.	Wikipedia, Wikidata, e-Stat, Statistical LOD, JMA를 사용한다. 명칭, 도도부현, 좌표, 공식 사이트 출처를 검증한다.
Attraction	일정 카드와 추천 상세 화면에 노출되는 관광지 데이터다. 자동 수집 후 운영시간, 운영기간, 입장료, 사진을 공식 출처로 보강한다.	JNTO, JTA, 공식 관광 사이트, Wikidata를 사용한다. City 매핑, 좌표, 운영 정보, 확인일을 검증한다.
Festival	월별 추천과 계절성 추천의 근거가 되는 축제·행사 데이터다. 연도별 기간 변동 여부를 Web Search Worker와 수동 검수로 확인한다.	JNTO, JTA, 지자체 공식 관광 사이트를 사용한다. 개최지, 기간, 공식 링크, 사진 조건을 검증한다.
Statistics	추천 점수와 지역 보조 지표에 사용하는 통계 데이터다. 방문객 수와 관광 통계를 City 기준으로 연결한다.	JNTO Statistics, RESAS, e-Stat을 사용한다. 기준 연도, 지역 코드, 지표 정의를 검증한다.


1.4 운영 및 검증 체크리스트

점검 항목	확인 내용	산출물
수집 전 정의	필드명, 데이터 유형, 원문 값과 정규화 값, 필수 여부를 사전에 확정한다.	필드 사전, 수집 매트릭스
파일럿 수집	대표 도시 1개 이상을 대상으로 자동 수집과 공식 확인 흐름을 먼저 실행한다.	파일럿 로그, 누락 필드 목록
취득 상태 분류	모든 필드는 collected, needs_review, missing, blocked 중 하나로 분류한다.	취득 상태 JSON
공식 출처 검증	운영시간, 운영기간, 입장료, 축제 기간은 공식 사이트 또는 공공 관광 페이지를 우선한다.	검증 URL, 확인일, 검증 메모
법적 검토	설명문은 내부 요약문으로 재작성하고 사진은 사용 가능 조건을 확인한다.	라이선스 메모, 차단 사유
저장 및 접근	Raw JSON, 정규화 JSON, 출처 메타데이터, 검수 메타데이터를 분리 저장한다.	Raw 저장소, 정규화 JSON, 메타데이터 로그

2. 목표 데이터 모델

2.1 관계 구조

City



관계	설명
City 1:N Attraction	하나의 일본 도시는 여러 관광지를 가진다.
City 1:N Festival	하나의 일본 도시는 여러 축제·행사를 가진다.

2.2 City 데이터

City는 추천의 기준 지역이다. 일본 목적지는 시·정·촌·구 단위의 소도시를 기본 단위로 관리한다.

필드	수집 방식	수집 상태	설명
city_id	내부 생성	전부 수집	시스템 내부 지역 식별자
city_name_ko	Wikipedia / 수동 정규화	전부 수집	한국어 도시명
city_name_ja	Wikipedia / Wikidata	전부 수집	일본어 원문 도시명
prefecture	Wikipedia / 행정구역 데이터	전부 수집	도도부현
location	Wikipedia / Wikidata	전부 수집	위치 정보, 좌표 또는 행정 위치
latitude	Wikipedia / Wikidata	전부 수집	대표 위도
longitude	Wikipedia / Wikidata	전부 수집	대표 경도
description	Wikipedia 기반 요약	전부 수집	도시 역사·문화·특징 설명
climate	Wikipedia / JMA 보조	전부 수집	기후 개요 또는 월별 기후 메모
site_url	Wikipedia 외부 링크 / 공식 관광 사이트	전부 수집	도시 또는 관광 공식 사이트

2.3 Attraction 데이터

Attraction은 도시와 1:N 관계를 가지며, 일정 카드와 추천 결과 상세 화면의 핵심 소재로 사용한다.

필드	수집 방식	수집 상태	설명
attraction_id	내부 생성	전부 수집	관광지 식별자
city_id	City 매핑	전부 수집	소속 도시
name	JNTO / JTA	전부 수집	관광지명
address	JNTO / JTA / 공식 사이트	전부 수집	주소
description	JNTO / JTA 기반 요약	전부 수집	관광지 설명
site_url	JNTO / JTA / 공식 사이트	전부 수집	공식 또는 안내 페이지
opening_hours	공식 사이트 / 검수	전부 수집	운영시간
opening_period	공식 사이트 / 검수	전부 수집	계절 운영기간
latitude	JNTO / Wikidata / 지도 보조	전부 수집	위도
longitude	JNTO / Wikidata / 지도 보조	전부 수집	경도
admission_fee	공식 사이트 / 검수	전부 수집	입장료
photo_url	JNTO / 공식 사이트 / 검수	전부 수집	대표 사진 URL

2.4 Festival 데이터

Festival은 도시와 1:N 관계를 가지며, 월별 추천과 계절성 추천의 주요 근거로 사용한다.

필드	수집 방식	수집 상태	설명
festival_id	내부 생성	전부 수집	축제 식별자
city_id	City 매핑	전부 수집	개최 도시
name	JNTO / JTA	전부 수집	축제명
address	JNTO / JTA / 공식 사이트	전부 수집	개최 장소 주소
period	JNTO / JTA / 공식 사이트	전부 수집	개최 기간 또는 개최 월
description	JNTO / JTA 기반 요약	전부 수집	축제 설명
site_url	JNTO / JTA / 공식 사이트	전부 수집	공식 또는 안내 페이지
photo_url	JNTO / 공식 사이트 / 검수	전부 수집	대표 사진 URL

3. 데이터 소스 전략

3.1 Wikipedia

항목	내용
주 용도	도시 정보
취득 대상	도시명, 위치, 설명, 기후, 사이트 링크
장점	도시 정보가 체계적이고 전국 단위 커버가 가능하다. 일부 도시는 기후 정보와 공식 사이트 링크도 확보할 수 있다.
한계	관광지·축제 상세 정보는 불완전할 수 있고, 설명문 사용 시 라이선스 표기가 필요하다.
적용 방식	City 자동 수집의 1차 소스로 사용한다.

3.2 JNTO 관광 데이터

항목	내용
주 용도	관광지 정보, 축제 정보
취득 대상	관광지명, 주소, 설명, 사이트 링크, 축제명, 기간, 축제 설명
장점	일본 공식 관광 데이터로 신뢰도가 높고, 관광지·축제 정보 품질이 좋다.
한계	운영시간, 입장료, 사진은 항목별 누락 가능성이 있다.
적용 방식	Attraction과 Festival 자동 수집의 1차 소스로 사용한다.

3.3 JTA 관광 DB

항목	내용
주 용도	관광지 상세 설명, 축제 상세 설명
취득 대상	관광지 설명, 문화 정보, 지역 특산품, 축제 설명
장점	설명 데이터 품질이 높고 전국 단위 보강에 적합하다.
한계	실제 제공 데이터 구조와 이용 조건 확인이 필요하다.
적용 방식	JNTO 데이터의 설명 보강 소스로 사용한다.

3.4 일본 정부 통계 및 JNTO Statistics

항목	내용
주 용도	통계 데이터
취득 대상	방문객 수, 관광 통계, 지역별 통계
장점	추천 품질 향상과 혼잡도·수요 분석에 활용할 수 있다.
한계	추천 점수에 바로 반영하려면 지표 해석 기준을 추가로 정의해야 한다.
적용 방식	지역별 방문객 수와 관광 통계를 함께 수집하고 City 기준 보조 지표로 연결한다.

3.5 보조 공식·공공 출처

출처	사용 목적	적용 방식
e-Stat / Statistical LOD	행정구역 코드, 지역 통계, 시정촌 메타데이터	City 정규화와 통계 보강
국토교통성 국토수치정보	좌표, 행정구역, 철도역·교통 데이터	위치·접근성 데이터 취득
일본기상청(JMA)	월별 기후·관측 데이터	기후 데이터 취득
도도부현·시정촌 공식 관광 사이트	운영시간, 입장료, 최신 축제 일정 확인	누락·최신성 확인

4. 전체 취득 범위

4.1 전체 수집 대상

아래 항목은 모두 최초 취득 대상으로 둔다. 자동 수집에서 누락되거나 신뢰도가 낮은 것은 제외하지 않고 공식 사이트 확인, Web Search Worker, 수동 검수로 이어서 채운다.

구분	수집 항목	주요 출처	누락 시 처리
도시	도시명, 위치, 설명, 기후, 사이트 링크, 위도, 경도	Wikipedia, Wikidata, JMA	공식 확인
관광지	관광지명, 운영시간, 운영기간, 주소, 위도, 경도, 설명, 입장료, 사이트 링크, 사진	JNTO, JTA, 공식 사이트, Wikidata	검색 또는 검수
축제	축제명, 주소, 기간, 설명, 사진, 사이트 링크	JNTO, JTA, 공식 사이트	공식 확인

4.2 취득 상태 관리

취득 상태	기준	처리 방식
collected	자동 수집 값이 있고 출처가 명확함	정규화 JSON 저장
needs_review	값은 있으나 표현이 모호하거나 최신성 확인이 필요함	수동 검수
missing	자동 수집에서 값을 찾지 못함	Web Search 또는 수동 입력 대상
blocked	약관·저작권·접근 제한으로 수집 불가	딥링크 또는 빈 값으로 대체하고 사유 기록

4.3 공식 확인 우선순위

항목	확인 우선순위	사유
운영시간	높음	사용자 질문 빈도가 높고 일정 구성에 직접 영향을 준다.
운영기간	높음	계절 운영, 휴관일, 임시 중단 등 예외가 많다.
입장료	중간	무료·유료·계절 요금·패키지 요금이 혼재한다.
사진	중간	저작권과 외부 핫링크 문제가 있어 검증이 필요하다.
위도·경도	높음	지도 표시와 동선 계산에 필요하다.

공식 사이트 또는 수동 검수로 확인한 값에는 `verified_at`, `verified_source_url`, `verification_note`를 함께 기록한다.

5. 수집 전략

5.1 자동 수집 전략

대상	자동 수집 소스	처리 방식
도시	Wikipedia, Wikidata, JMA	도시명, 위치, 설명, 기후, 사이트 링크, 위도, 경도를 추출하고 City 테이블로 정규화한다.
관광지	JNTO, JTA, 공식 사이트, Wikidata	관광지명, 운영시간, 운영기간, 주소, 위도, 경도, 설명, 입장료, 사이트 링크, 사진을 추출하고 City와 매핑한다.
축제	JNTO, JTA, 공식 사이트	축제명, 주소, 기간, 설명, 사진, 사이트 링크를 추출하고 City와 매핑한다.
통계	JNTO Statistics, e-Stat, RESAS	방문객 수, 관광 통계, 지역별 지표를 수집하고 City 기준 보조 지표로 연결한다.

5.2 공식 확인 및 검수 전략

공식 확인과 검수는 자동 수집에서 실패했거나 검수 필요 상태로 분류된 항목에 적용한다. 이 과정은 별도 단계가 아니라 같은 취득 파이프라인의 후속 처리로 본다.


확인 항목	입력 기준
운영시간	공식 사이트에 명시된 최신 운영시간만 입력
운영기간	계절 운영 또는 축제 기간이 명확한 경우 입력
입장료	공식 사이트 또는 공공 관광 페이지에 있는 금액만 입력
사진	사용 가능 조건이 명확한 공식 이미지 또는 내부 제작 이미지 사용

5.3 데이터 정규화 규칙

- 도시명은 city_name_ja, city_name_ko, city_name_en을 분리 저장한다.
- 관광지와 축제는 반드시 city_id를 가진다.
- 기간 정보는 원문 문자열(period_text)과 정규화 값(start_date, end_date, month)을 함께 저장한다.
- 운영시간과 입장료는 최신성이 낮을 수 있으므로 data_confidence를 별도 기록한다.
- 외부 설명문은 원문 복제가 아니라 내부 요약문으로 재작성한다.

6. 단일 취득 파이프라인

6.1 처리 흐름



정의된 모든 필드가 DB에 들어가도록 시도하는 것이 목표다. 운영시간·입장료·사진도 최초 수집 대상에 포함하며, 자동 수집 실패 시 `missing` 또는 `needs_review` 상태로 남기고 같은 파이프라인 안에서 공식 확인 또는 수동 검수로 채운다.

예시:

사용자 질문: 도쿄타워 운영시간 알려줘

1. DB에서 도쿄타워 Attraction 조회
2. `opening_hours`가 없거나 오래된 값이면 Web Search Worker 실행
3. 공식 사이트 또는 공식 관광 페이지 확인
4. 운영시간과 확인 출처를 함께 반환

6.2 Web Search Worker 적용 조건

조건	처리
DB에 정보 없음	공식 사이트 검색
운영시간·입장료 값이 오래됨	공식 사이트 재확인
축제 기간이 연도별로 바뀜	해당 연도 공식 페이지 확인
공식 출처가 아닌 블로그·SNS만 존재	답변 근거로 사용하지 않거나 낮은 신뢰도로 표시

7. 저장 구조

일본 데이터는 초기 취득 단계에서 관계형 테이블이 아니라 JSON 파일로 저장한다. JSON 파일 안에서는 City를 기준 객체로 두고, 해당 도시의 Attraction과 Festival을 배열로 포함한다.

7.1 JSON 파일 구성

구분	저장 내용	예시 파일명
도시 단위 JSON	하나의 City와 해당 도시의 Attraction, Festival 목록을 함께 저장한다.	city/ kanazawa.json
원본 수집 JSON	API 응답, HTML 수집 결과, 공식 사이트 확인 결과를 원본 형태로 보관한다.	raw/jnto.json
검수 메타데이터 JSON	취득 상태, 확인일, 확인 출처, 검수 메모를 별도 기록한다.	review/ kanazawa.json

7.2 JSON 구조 예시

JSON 키	저장 내용	예시 값
city	도시명, 도도부현, 좌표, 소개, 공식 관광 사이트, 기후 요약을 저장한다.	city_id JP-ISHIKAWA-KANAZAWA
attractions	해당 City에 속한 관광지 배열이다. 주소, 좌표, 운영시간, 입장료, 출처를 항목별로 저장한다.	name Kenrokuen
festivals	해당 City에 속한 축제 배열이다. 개최 장소, 기간, 공식 링크, 사진 사용 조건을 항목별로 저장한다.	name Hyakumangoku Festival
metadata	수집 상태, 수집일, 검수일, 검수자, 확인 출처를 저장한다.	status needs_review

7.3 저장 원칙

- City, Attraction, Festival의 관계는 JSON 내부의 중첩 구조로 표현한다.
- 모든 객체에는 수집 상태와 출처 메타데이터를 함께 기록한다.
- 운영시간, 입장료, 축제 기간처럼 변경 가능성이 높은 값에는 확인일과 확인 출처를 포함한다.
- 원본 수집 JSON과 정규화 JSON은 분리하여 보관한다.
- 추후 DB 적재가 필요할 경우 JSON 파일을 기준으로 테이블 또는 컬렉션으로 변환한다.

8. 품질 검증 기준

검증 항목	기준
City 매핑	모든 Attraction과 Festival은 하나의 City에 연결되어야 한다.
출처 기록	모든 자동 수집 데이터는 source_name, source_url, collected_at을 가진다.
전체 필드 상태	정의된 모든 필드는 collected, needs_review, missing, blocked 중 하나의 상태를 가진다.
최신성	운영시간, 운영기간, 입장료는 확인일을 기록한다.
저작권	사진과 설명문은 사용 가능 조건을 확인한다. 설명문은 내부 요약문으로 저장한다.
공식성	자동 수집과 Web Search Worker는 공식 사이트 또는 공공 관광 페이지를 우선한다.

9. 법적·운영 제약

- Wikipedia 기반 설명은 라이선스 조건에 따라 출처와 원문 링크를 기록한다.
- JNTO, JTA, 지자체 관광 페이지는 이용약관과 크롤링 허용 범위를 확인한다.
- 사진은 저작권 위험이 크므로 자동 수집 값이 있더라도 사용 가능 조건을 확인하고, 불명확하면 needs_review 또는 blocked로 관리한다.
- 상업 플랫폼의 숙박·맛집 데이터는 직접 저장보다 딥링크 제공을 우선한다.
- 운영시간과 입장료는 변경 가능성이 높으므로 "확인일 기준" 문구를 서비스에 표시한다.

10. 데이터 취득 결과서 작성 계획

이 초안이 확정되면 다음 항목을 데이터 취득 결과서에 작성한다.

- 일본 데이터 출처 항목에 Wikipedia, JNTO, JTA, JNTO Statistics의 역할을 표로 작성한다.
- 데이터 전처리 방식 및 인프라 구성 항목에 자동 수집, 공식 확인, Web Search Worker, 검수 흐름을 작성한다.
- 데이터 품질 정합성 관리 방법 항목에 City 매핑, 출처 기록, 최신성 검증을 작성한다.
- 수집 정책 및 제외 범위 항목에 전체 필드 일괄 취득 원칙과 최신성 재확인 정책을 작성한다.

11. 참고 출처

- Wikipedia: <https://www.wikipedia.org/>
- JNTO: <https://www.jnto.go.jp/>
- Japan Tourism Statistics: <https://statistics.jnto.go.jp/en/>
- e-Stat API: <https://www.e-stat.go.jp/api/>
- Statistical LOD Area Data: <https://data.e-stat.go.jp/lodw/index.php/en/provdata/lodRegion>
- 국토교통성 국토수치정보: <https://nlftp.mlit.go.jp/ksj/>
- 일본기상청 기후 데이터: <https://www.data.jma.go.jp/stats/data/en/index.html>

12. 변경 이력

버전	날짜	작성자	변경 내용
v0.1	2026-06-02	로브 기획팀	일본 데이터 취득 계획서 초안 작성
v0.2	2026-06-02	로브 기획팀	데이터 모델, 자동 수집·검수 범위, Web Search Worker 확인 전략 구체화
v0.3	2026-06-02	로브 기획팀	정의 필드를 모두 수집하고 누락 항목은 취득 상태로 관리하는 방향 반영
v0.4	2026-06-02	로브 기획팀	단계 경계를 제거하고 전체 필드 일괄 취득 전략으로 재정리
v0.5	2026-06-03	로브 기획팀	PDF 양식 가독성 개선, 문서 관리표, 수집 매트릭스, JSON 저장 구조, 결과서 작성 계획 반영