

한국 데이터 취득 계획서

로브 서비스 한국 데이터 취득 계획

조라에몽의 만능 도구들

이창우, 전승권, 전종혁, 조동휘, 최수아

멘토 최민수

2026-05-30

Contents

1. 목적	2
2. 목표 데이터 모델	3
2.1 관계 구조	3
2.2 City 데이터	3
2.3 Attraction 데이터	4
2.4 Festival 데이터	5
3. 데이터 소스 전략	6
3.1 한국관광공사 TourAPI	6
3.2 대한민국구석구석 및 지자체 문화관광 홈페이지	6
3.3 Wikipedia API / Wikipedia 크롤링 / Wikidata	7
3.4 기상청 API허브 및 기후통계	7
3.5 관광 통계 및 보조 공공데이터	8
4. 전체 취득 범위	9
4.1 전체 수집 대상	10
4.2 취득 상태 관리	11
4.3 공식 확인 우선순위	12
5. 수집 전략	13
5.1 자동 수집 전략	13
5.2 공식 확인 및 검수 전략	13
5.3 데이터 정규화 규칙	14
6. 단일 취득 파이프라인	15
6.1 처리 흐름	15
6.2 Web Search Worker 적용 조건	16
7. 저장 구조	17
7.1 핵심 테이블	17
7.2 City 예시	17
7.3 Attraction 예시	18
7.4 Festival 예시	18
8. 품질 검증 기준	19
9. 법적·운영 제약	20
10. 본 문서 반영 계획	21
11. 참고 출처	22
12. 변경 이력	23


1. 목적

본 문서는 여행 추천 Multi-Agent 서비스에서 한국 소도시 추천에 필요한 도시·관광지·축제 데이터를 한 번에 취득하기 위한 범위, 데이터 소스, 검증 방식, 저장 구조를 정의한다. 이번 초안의 핵심은 다음과 같다.

- City, Attraction, Festival의 정의된 항목을 모두 수집 대상으로 둔다.
- 도의 간략 정보와 산하 도시 목록을 먼저 취득하고, 산하 도시 목록에 포함된 City만 Wikipedia 문서 크롤링 대상으로 둔다.
- 한국관광공사 TourAPI와 대한민국구석구석 기반 데이터를 중심으로 관광지·축제 정보를 취득한다.
- 취득 결과는 JSON 문서로 저장한 뒤 S3 Raw Bucket에 적재한다.
- 운영시간, 운영기간, 입장료, 사진처럼 출처별 표현 차이가 큰 항목도 최초 취득 범위에 포함한다.
- 자동 수집, 공식 사이트 확인, Web Search Worker, 수동 검수를 하나의 취득 파이프라인으로 묶어 처리한다.
- 추천 DB는 City 1:N Attraction, City 1:N Festival 관계를 기준으로 설계한다.

2. 목표 데이터 모델

2.1 관계 구조



관계	설명
City 1:N Attraction	하나의 한국 도시는 여러 관광지를 가진다.
City 1:N Festival	하나의 한국 도시는 여러 축제·행사를 가진다.

2.2 City 데이터

City는 추천의 기준 지역이다.

한국 목적지는 시·군·구 단위의 소도시를 기본 단위로 관리한다.

도 단위 문서에서는 간략 정보와 산하 도시 목록만 취득하고, 상세 정보 크롤링은 이 산하 도시 목록에 포함된 City만 대상으로 한다.

필드	수집 방식	수집 상태	설명
city_id	내부 생성	전부 수집	시스템 내부 지역 식별자
city_name_ko	도 산하 도시 목록 / Wikipedia 크롤링 / 행정구역 데이터 / 수동 정규화	전부 수집	한국어 도시명
province	도 간략 정보 / 행정구역 데이터	전부 수집	도 또는 광역 행정구역
district_type	행정구역 데이터	전부 수집	시·군·구 구분
location	산하 도시 Wikipedia 크롤링 / TourAPI / 행정구역 데이터	전부 수집	위치 정보, 좌표 또는 행정 위치
latitude	산하 도시 Wikipedia 크롤링 / TourAPI / Wikidata / 지도 보조	전부 수집	대표 위도
longitude	산하 도시 Wikipedia 크롤링 / TourAPI / Wikidata / 지도 보조	전부 수집	대표 경도
description	산하 도시 Wikipedia 크롤링 기반 요약 / 대한민국구석구석 기반 요약	전부 수집	도시 역사·문화·특징 설명
climate	Wikipedia 취득 후 기상청 API허브 / 기후통계와 비교	전부 수집	기후 개요 또는 월별 기후 메모
site_url	지자체 문화관광 홈페이지 / 대한민국구석구석	전부 수집	도시 또는 관광 공식 사이트

2.3 Attraction 데이터

Attraction은 도시와 1:N 관계를 가지며, 일정 카드와 추천 결과 상세 화면의 핵심 소재로 사용한다.

필드	수집 방식	수집 상태	설명
attraction_id	내부 생성	전부 수집	관광지 식별자
city_id	City 매핑	전부 수집	소속 도시
content_id	한국관광공사 TourAPI	전부 수집	TourAPI 콘텐츠 ID
content_type_id	한국관광공사 TourAPI	전부 수집	관광지·문화시설·음식점 등 콘텐츠 유형
name	TourAPI / 대한민국구석구석	전부 수집	관광지명
address	TourAPI / 공식 사이트	전부 수집	주소
description	TourAPI 공통정보·소개정보 기반 요약	전부 수집	관광지 설명
site_url	TourAPI / 공식 사이트	전부 수집	공식 또는 안내 페이지
opening_hours	TourAPI 소개정보 / 공식 사이트 / 검수	전부 수집	운영시간
opening_period	TourAPI 소개정보 / 공식 사이트 / 검수	전부 수집	계절 운영기간
latitude	TourAPI 위치정보	전부 수집	위도
longitude	TourAPI 위치정보	전부 수집	경도
admission_fee	TourAPI 소개정보 / 공식 사이트 / 검수	전부 수집	입장료
photo_url	TourAPI 이미지정보 / 공식 사이트 / 검수	전부 수집	대표 사진 URL

2.4 Festival 데이터

Festival은 도시와 1:N 관계를 가지며, 월별 추천과 계절성 추천의 주요 근거로 사용한다.

필드	수집 방식	수집 상태	설명
festival_id	내부 생성	전부 수집	축제 식별자
city_id	City 매핑	전부 수집	개최 도시
content_id	한국관광공사 TourAPI	전부 수집	TourAPI 행사 콘텐츠 ID
name	TourAPI 행사정보 / 대한민국구석구석	전부 수집	축제명
address	TourAPI / 공식 사이트	전부 수집	개최 장소 주소
period	TourAPI 행사 시작일·종료일 / 공식 사이트	전부 수집	개최 기간 또는 개최 월
description	TourAPI 공통정보·소개정보 기반 요약	전부 수집	축제 설명
site_url	TourAPI / 공식 사이트	전부 수집	공식 또는 안내 페이지
photo_url	TourAPI 이미지정보 / 공식 사이트 / 검수	전부 수집	대표 사진 URL

3. 데이터 소스 전략

3.1 한국관광공사 TourAPI

항목	내용
주 용도	관광지 정보, 축제 정보, 이미지 정보, 지역 기반 관광정보
취득 대상	관광지명, 주소, 위도, 경도, 설명, 운영시간, 입장료, 이미지, 축제명, 축제 기간
장점	전국 관광정보를 API로 제공하며 지역기반·위치기반·키워드검색·행사정보·이미지정보 등을 함께 조회할 수 있다.
한계	운영시간·입장료·휴무일은 콘텐츠 유형별 필드가 다르고 누락될 수 있다.
적용 방식	Attraction과 Festival 자동 수집의 1차 소스로 사용한다.

3.2 대한민국구석구석 및 지자체 문화관광 홈페이지

항목	내용
주 용도	도시 관광 링크, 공식 설명, 최신 운영정보 확인
취득 대상	지자체 문화관광 홈페이지 URL, 관광지 상세 링크, 축제 상세 링크, 공지성 최신 정보
장점	공식 또는 준공식 관광 안내 성격이 강해 서비스 설명과 출처 표기에 적합하다.
한계	페이지 구조가 지자체마다 다르고, 운영시간·요금 표기 방식이 일정하지 않다.
적용 방식	TourAPI 수집값의 공식 확인 및 최신성 검증 소스로 사용한다.

3.3 Wikipedia API / Wikipedia 크롤링 / Wikidata

항목	내용
주 용도	도 간략 정보, 산하 도시 목록, 산하 도시 위치 정보와 역사·문화 개요
취득 대상	도 이름, 도 간략 설명, 산하 도시 목록, 산하 도시명, 위치, 설명, 대표 좌표, 외부 링크
장점	도 단위에서 크롤링 대상 City 목록을 먼저 확정하고, 산하 도시 단위 설명과 위치 정보를 체계적으로 취득할 수 있다.
한계	관광지·축제 상세 정보는 불완전할 수 있고, 설명문 사용 시 라이선스 표기가 필요하다.
적용 방식	Wikipedia API로 도의 간략 정보와 산하 도시 목록을 우선 확보하고, 산하 도시 목록에 포함된 City 문서만 Wikipedia 크롤링 대상으로 삼아 설명·위치·외부 링크를 추출한다.

3.4 기상청 API허브 및 기후통계

항목	내용
주 용도	Wikipedia 기반 기후 데이터의 비교 검증, 월별 여행 적합도 보강
취득 대상	Wikipedia 기후 개요와 비교할 월별 평균 기온, 강수량, 폭염·한파·강설 등 계절성 메모
장점	공식 기상기후 데이터로 Wikipedia 취득값의 정합성을 확인하고 월별 추천 근거를 만들 수 있다.
한계	시·군·구와 관측 지점 매핑 기준을 별도로 정의해야 한다.
적용 방식	City의 climate는 Wikipedia에서 먼저 취득하고, 기상청 API허브·기후통계와 비교해 불일치 여부와 보정 메모를 기록한다.

3.5 관광 통계 및 보조 공공데이터

출처	사용 목적	적용 방식
한국관광 데이터랩	지역별 관광 동향, 방문자 통계, 관광 수요 참고	City 기준 보조 지표
행정안전부 행정구역 데이터	시·군·구 코드와 행정구역 정규화	City ID와 지역 매핑
공공데이터포털 지자체 관광 데이터	지자체별 관광 링크·관광 자원 보강	공식 링크와 누락 데이터 보강
지자체 공식 문화관광 사이트	운영시간, 입장료, 최신 축제 일정 확인	누락·최신성 확인

4. 전체 취득 범위

4.1 전체 수집 대상

아래 항목은 모두 최초 취득 대상으로 둔다.

자동 수집에서 누락되거나 신뢰도가 낮은 것은 제외하지 않고 공식 사이트 확인, Web Search Worker, 수동 검수로 이어서 채운다.

구분	수집 항목	주요 출처	누락 시 처리
도시	도 간략 정보, 산하 도시 목록, 도시명, 위치, 설명, 기후, 사이트 링크, 위도, 경도	Wikipedia API, Wikipedia 크롤링, Wikidata, 기상청 비교 자료, 지자체 관광 사이트	
관광지	관광지명, 운영시간, 운영기간, 주소, 위도, 경도, 설명, 입장료, 사이트 링크, 사진	TourAPI, 대한민국구석구석, 공식 사이트	
축제	축제명, 주소, 기간, 설명, 사진, 사이트 링크	TourAPI 행사정보, 대한민국구석구석, 공식 사이트	
통계	방문자 수, 지역별 관광 동향, 혼잡 참고 지표	한국관광 데이터랩, 공공데이터포털	

4.2 취득 상태 관리

취득 상태	기준	처리 방식
collected	자동 수집 값이 있고 출처가 명확함	DB 적재
needs_ review	값은 있으나 표현이 모호하거나 최신성 확인이 필요함	수동 검수
missing	자동 수집에서 값을 찾지 못함	Web Search 또는 수동 입력 대상
blocked	약관·저작권·접근 제한으로 수집 불가	딥링크 또는 빈 값으로 대체 하고 사유 기록

4.3 공식 확인 우선순위

항목	확인 우선순위	사유
운영시간	높음	사용자 질문 빈도가 높고 일정 구성에 직접 영향을 준다.
운영기간	높음	계절 운영, 휴관일, 임시 중단 등 예외가 많다.
입장료	중간	무료·유료·계절 요금·패키지 요금이 혼재한다.
사진	중간	공공누리 유형과 외부 이미지 사용 조건 확인이 필요하다.
위도·경도	높음	지도 표시와 동선 계산에 필요하다.

공식 사이트 또는 수동 검수로 확인한 값에는 `verified_at`, `verified_source_url`, `verification_note`를 함께 기록한다.

5. 수집 전략

5.1 자동 수집 전략

대상	자동 수집 소스	처리 방식
도시	Wikipedia API, Wikipedia 크롤링, Wikidata, 행정구역 데이터, 기상청	Wikipedia API로 도 간략 정보와 산하 도시 목록을 먼저 추출하고, 산하 도시 목록에 포함된 City 문서만 크롤링해 설명·위치·외부 링크·기후를 추출한다. 기후는 기상청 자료와 비교한 뒤 City 테이블로 정규화한다.
관광지	TourAPI, 대한민국구석구석, 공식 사이트	관광지명, 운영시간, 운영기간, 주소, 위도, 경도, 설명, 입장료, 사이트 링크, 사진을 추출하고 City와 매핑한다.
축제	TourAPI 행사정보, 대한민국구석구석, 공식 사이트	축제명, 주소, 기간, 설명, 사진, 사이트 링크를 추출하고 City와 매핑한다.
통계	한국관광 데이터랩, 공공데이터포털	방문객 수, 관광 통계, 지역별 지표를 수집하고 City 기준 보조 지표로 연결한다.

5.2 공식 확인 및 검수 전략

공식 확인과 검수는 자동 수집에서 실패했거나 검수 필요 상태로 분류된 항목에 적용한다. 이 과정은 별도 단계가 아니라 같은 취득 파이프라인의 후속 처리로 본다.


확인 항목	입력 기준
운영시간	공식 사이트에 명시된 최신 운영시간만 입력
운영기간	계절 운영 또는 축제 기간이 명확한 경우 입력
입장료	공식 사이트 또는 공공 관광 페이지에 있는 금액만 입력
사진	공공누리 유형 또는 사용 가능 조건이 명확한 이미지 사용

5.3 데이터 정규화 규칙

- 도시명은 city_name_ko, city_name_en을 분리 저장한다.
- 시·군·구는 행정구역 코드와 내부 city_id를 매핑한다.
- 도 간략 정보와 산하 도시 목록의 Wikipedia API 응답 원본, 산하 도시 Wikipedia HTML 크롤링 원본을 Raw 데이터로 보존한다.
- 관광지와 축제는 반드시 city_id를 가진다.
- TourAPI의 contentid, contenttypeid, areacode, sigungucode, cat1, cat2, cat3를 원본 참조 필드로 저장한다.
- 기간 정보는 원문 문자열(period_text)과 정규화 값(start_date, end_date, month)을 함께 저장한다.
- 운영시간과 입장료는 최신성이 낮을 수 있으므로 data_confidence를 별도 기록한다.
- 외부 설명문은 원문 복제가 아니라 내부 요약문으로 재작성한다.

6. 단일 취득 파이프라인

6.1 처리 흐름



정의된 모든 필드가 JSON 원본으로 저장되도록 시도하는 것이 목표다.

수집 결과는 엔티티 유형과 출처별 JSON 문서로 직렬화한 뒤 S3 Raw Bucket에 먼저 적재한다.

Raw 원본은 재사용과 재처리를 위해 일정 기간 누적 보관하고, 보관 기간 또는 배치 기준이 충족되면 Lambda가 전처리한 뒤 DynamoDB에 적재한다.

운영시간·입장료·사진도 최초 수집 대상에 포함하며, 자동 수집 실패 시 `missing` 또는 `needs_review` 상태로 남기고 같은 파이프라인 안에서 공식 확인 또는 수동 검수로 채운다.

예시:

- text**
사용자 질문: 순천만국가정원 운영시간 알려줘
1. DB에서 순천만국가정원 Attraction 조회
 2. `opening_hours`가 없거나 오래된 값이면 Web Search Worker 실행
 3. 공식 사이트 또는 공식 관광 페이지 확인
 4. 운영시간과 확인 출처를 함께 반환

6.2 Web Search Worker 적용 조건

조건	처리
DB에 정보 없음	공식 사이트 검색
운영시간·입장료 값이 오래됨	공식 사이트 재확인
축제 기간이 연도별로 바뀜	해당 연도 공식 페이지 확인
공식 출처가 아닌 블로그·SNS만 존재	답변 근거로 사용하지 않거나 낮은 신뢰도로 표시

7. 저장 구조

7.1 핵심 테이블

```

text
City
Attraction
Festival
S3 Raw Bucket

```

수집 원본은 DB에 바로 쓰지 않고 JSON 파일로 저장한 뒤 S3 Raw Bucket에 적재한다. S3 객체는 국가, 출처, 엔티티 유형, 수집일 기준 Prefix로 구분한다. 일정 기간 누적된 Raw Prefix는 Lambda 배치 전처리의 입력으로 재사용하며, 전처리 결과만 DynamoDB에 정규화 Item으로 적재한다.

7.2 City 예시

필드	예시
city_id	KR-JEONNAM-SUNCHEON
city_name_ko	순천
province	전라남도
district_type	시
description	순천만과 정원 관광 자원이 강한 전남 동부의 생태 관광 도시
climate	남해안 영향으로 겨울이 비교적 온화하고 봄·가을 생태 관광 적합도가 높다.
site_url	공식 문화관광 사이트 URL

7.3 Attraction 예시

필드	예시
name	순천만국가정원
city_id	KR-JEONNAM-SUNCHEON
address	전라남도 순천시 국가정원1호길
description	정원·습지·생태 관광을 결합한 순천 대표 관광지
opening_hours	공식 사이트 확인값
admission_fee	공식 사이트 확인값
site_url	공식 사이트 URL

7.4 Festival 예시

필드	예시
name	순천만갈대축제
city_id	KR-JEONNAM-SUNCHEON
address	전라남도 순천시 순천만 일대
period	매년 가을
description	순천만 갈대와 생태 자원을 중심으로 열리는 지역 축제
photo_url	공식 또는 사용 가능 조건이 확인된 이미지 URL

8. 품질 검증 기준

검증 항목	기준
City 매핑	모든 Attraction과 Festival은 하나의 City에 연결되어야 한다.
출처 기록	모든 자동 수집 데이터는 source_name, source_url, collected_at을 가진다.
전체 필드 상태	정의된 모든 필드는 collected, needs_review, missing, blocked 중 하나의 상태를 가진다.
최신성	운영시간, 운영기간, 입장료는 확인일을 기록한다.
기후 정합성	Wikipedia에서 취득한 City climate를 기상청 API허브·기후통계와 비교하고 불일치 여부를 검수 메타데이터로 남긴다.
저작권	사진과 설명문은 사용 가능 조건을 확인한다. 설명문은 내부 요약문으로 저장한다.
공식성	자동 수집과 Web Search Worker는 공식 사이트 또는 공공 관광 페이지를 우선한다.
행정구역 정합성	TourAPI 지역 코드와 내부 City ID가 같은 시·군·구를 가리키는지 검증한다.

9. 법적·운영 제약

- Wikipedia API 및 크롤링 기반 설명은 라이선스 조건에 따라 출처와 원문 링크를 기록한다.
- TourAPI와 공공데이터포털 데이터는 공공누리 유형, API 이용 조건, 출처 표기 조건을 확인한다.
- 지자체 관광 페이지는 이용약관과 크롤링 허용 범위를 확인한다.
- 사진은 저작권 위험이 크므로 자동 수집 값이 있더라도 사용 가능 조건을 확인하고, 불명확하면 `needs_review` 또는 `blocked`로 관리한다.
- 운영시간과 입장료는 변경 가능성이 높으므로 "확인일 기준" 문구를 서비스에 표시한다.

10. 본 문서 반영 계획

이 초안이 확정되면 다음 순서로 본 문서와 HTML에 반영한다.

- 04_data_collect_plan.md의 2.2 수집 데이터 정보 및 분량을 한국 City, Attraction, Festival 관계 기준으로 보강한다.
- 2.4.1 한국 데이터 출처에 TourAPI, 대한민국구석구석, 기상청, 행정구역 데이터의 역할을 표로 반영한다.
- 3. 데이터 전처리 방식 및 인프라 구성에 자동 수집, 공식 확인, Web Search Worker, 검수 흐름을 추가한다.
- 4. 데이터 품질 정합성 관리 방법에 City 매핑, TourAPI 코드 매핑, 출처 기록, 최신성 검증을 추가한다.
- 5. 법적 요소 검토에 TourAPI·공공누리·지자체 사이트 이용 조건을 추가한다.
- scripts/generate_pages.py를 실행하여 pages/04_data_collect_plan.html에 반영한다.

11. 참고 출처

- 한국관광공사 TourAPI 국문 관광정보 서비스: <https://www.data.go.kr/data/15101578/openapi.do>
- 대한민국구석구석: <https://korean.visitkorea.or.kr/>
- 한국관광 데이터랩: <https://datalab.visitkorea.or.kr/>
- 기상청 API허브: <https://apihub.kma.go.kr/>
- 공공데이터포털: <https://www.data.go.kr/>

12. 변경 이력

버전	날짜	작성자	변경 내용
v0.1	2026-06-02	LLM 파트	한국 데이터 취득 계획서 초안 작성
v0.2	2026-06-06	LLM 파트	도 간략 정보와 산하 도시 목록 기반 City 크롤링, JSON 원본의 S3 저장, 기후 데이터 비교 검증 방식으로 구체화