

데이터 전처리 보고서

KR 20260629 상세 데이터 전처리 결과

조라에몽의 만능 도구들

이창우, 전종혁, 조동휘, 최수아

멘토 최민수

2026-06-29

Contents

1. 보고서 개요	2
1.1 처리 기준	2
1.2 보고 범위	2
1.3 S3 전처리 후 적재 흐름	2
2. 최종 판단	4
2.1 완료 판단	4
2.2 핵심 지표	4
2.3 완료 기준	4
3. 전처리 결과	5
3.1 Lambda 실행 결과	5
3.2 S3 산출물	5
4. Wikipedia 보강 상태	6
4.1 매칭 현황	6
4.2 미매칭 원인	6
4.3 Raw 후보 없음 key	6
5. 이미지 S3 URL 치환 상태	7
5.1 URL 치환 현황	7
5.2 이미지 버킷 검증	7
6. Review 산출물 상태	8
6.1 Review queue 현황	8
6.2 Entity type 현황	8
7. 남은 리스크와 후속 작업	9
7.1 후속 작업 목록	9
8. 결론	10
8.1 전처리 완료 결론	10
8.2 품질 검토 우선순위	10
9. 변경 이력	11
9.1 변경 이력	11

1. 보고서 개요

1.1 처리 기준

전처리 기준일, 원천 위치, 실행 Lambda, 산출물 prefix를 먼저 고정해 이후 수치 검토의 기준을 명확히 한다.

항목	내용
작성일	2026-06-29
대상 프로젝트	02_lovv_data_collect
입력 날짜 형식	YYYYMMDD 형식으로 입력한다. 예: 20260629 = 2026-06-29
대상 원천 데이터	raw/KR/details/YYYYMMDD/ 이번 실행 예: raw/KR/details/20260629/
전처리 Lambda	kr-pipeline-transform
processed prefix	processed/KR/details/YYYYMMDD/ 이번 실행 예: processed/KR/details/20260629/

1.2 보고 범위

이 보고서는 2026-06-29 KR 상세 raw 240개에 대한 전처리 실행 결과와 후속 검토 대상을 한 흐름으로 정리한다. 주요 확인 범위는 품질 검토 대상, Wikipedia 보강 상태, 이미지 S3 URL 치환 상태다.

1.3 S3 전처리 후 적재 흐름

전처리 후 S3 적재는 raw 보존, Lambda 전처리, 결과 prefix 분리 순서로 진행된다. 입력 날짜는 실행 기준일을 YYYYMMDD 형식으로 적은 값이며, 예를 들어 2026-06-29 실행이면 입력 날짜는 20260629다. S3 prefix는 raw/KR/details/YYYYMMDD/와 processed/KR/details/YYYYMMDD/ 형식으로 구성한다.

- **Raw 보존:** 원천 JSON은 raw/KR/details/YYYYMMDD/에 저장한다. 이번 실행 예시는 raw/KR/details/20260629/이며, 수집 원본을 날짜별 prefix에 남겨 동일 기준으로 재처리할 수 있게 한다.
- **전처리 실행:** kr-pipeline-transform이 raw 객체를 순회하며 스키마 검증, 값 정리, 좌표와 날짜 정규화, 품질 분류를 수행한다. 이번 실행에서는 raw 객체 240개가 처리됐다.
- **정상 산출:** 정규화 결과는 processed/KR/details/YYYYMMDD/passed/에 저장한다. 이번 실행 예시는 processed/KR/details/20260629/passed/이며, passed/ 산출 item은 8,010건이다.
- **검토 산출:** 자동 확정이 어려운 품질 이슈와 보강 필요 항목은 processed/KR/details/YYYYMMDD/review/에 분리한다. 이번 실행의 Review record는 1,202건이다.

- **실패와 품질:** 처리 실패 원인과 품질 리포트는 각각 `failed/`, `quality/` 하위 prefix에 남긴다. 이번 실행의 실패 invocation은 0건이다.

추가 확인이 필요하면 02 프로젝트 담당 스레드에 아래 프롬프트를 전달한다.

확인 요청 프롬프트 02_lovv_data_collect의 KR 입력 날짜 YYYYMMDD 전처리 실행 기준으로, `kr-pipeline-transform`이 `raw/KR/details/YYYYMMDD/`를 읽어 `processed/KR/details/YYYYMMDD/passed/`, `review/`, `failed/`, `quality/`에 쓰는 정확한 S3 write 단계, manifest 생성 주체, 각 prefix별 JSON 스키마와 count 산정 기준을 확인해 주세요. 예시는 YYYYMMDD=20260629이며, 현재 보고서에는 raw 240개, passed/ 8,010 item, Review record 1,202건, S3 URL 치환 6,975건으로 반영하려 합니다.

2. 최종 판단

2.1 완료 판단

판단: 전처리 산출물 생성은 완료다. raw detail 240개가 모두 성공 처리됐고 전처리 실패 invocation은 0건이다. 남은 항목은 실패 복구가 아니라 품질 검토 queue와 외부 보강 정책 결정이다.

2.2 핵심 지표

판단 항목	결과
전처리 대상 raw detail	240개
kr-pipeline-transform 성공	240개
kr-pipeline-transform 실패	0건
passed/ 산출 item	8,010건
Review record	1,202건
Wikipedia matched	181건
Wikipedia missing	59건
S3 URL 치환 완료	6,975건
외부 image URL 잔존	0건

2.3 완료 기준

완료 기준은 raw detail 240개가 모두 성공 처리되고, passed/, review/, failed/, quality/ 산출물이 생성되었으며, 전처리 실패 invocation이 0건인 상태다.

3. 전처리 결과

3.1 Lambda 실행 결과

실행 성공 여부와 S3 산출물 위치를 분리해, 처리 결과와 저장 위치를 각각 확인할 수 있게 정리했다.

kr-pipeline-transform은 2026-06-29 raw detail 240개를 모두 처리했다.

항목	값
Manifest record count	240
Lambda invoked	240
Lambda succeeded	240
Failed invocations	0
Duplicate city ids	0
Failed raw keys	0

3.2 S3 산출물

S3 산출물은 다음 prefix에 생성되었다.

Prefix	JSON files
processed/KR/details/20260629/passed/	240
processed/KR/details/20260629/review/	240
processed/KR/details/20260629/failed/	240
processed/KR/details/20260629/quality/	240

4. Wikipedia 보강 상태

4.1 매칭 현황

Wikipedia 보강 항목은 전처리 실패가 아니라 city key와 raw 후보의 연결 상태로 해석한다.

항목	값
City metadata	240
Wikipedia matched	181
Wikipedia missing	59

4.2 미매칭 원인

wiki_status=missing 59건은 전처리 실패가 아니라 Wikipedia raw와 city key가 연결되지 않은 상태다.

후속 실사 기준으로 48건은 raw 후보가 있으나 -GU, -GUN 등 영문 key suffix 차이로 매칭되지 않았고, 11건은 raw 후보 자체가 없다.

4.3 Raw 후보 없음 key

Raw 후보가 없는 11개 key는 다음과 같다.

Raw 후보 없음 key	Raw 후보 없음 key
BUK-GU	BUKJEJU
CHEONGWON-GUN	DONG-GU
GANGSEO-GU	JINHAE
JUNG-GU	MASAN
NAM-GU	NAMJEJU
SEO-GU	

5. 이미지 S3 URL 치환 상태

5.1 URL 치환 현황

이미지 URL 치환은 외부 URL 잔존 여부와 원천 이미지 부재 항목을 분리해 확인한다.

항목	값
관광지/축제 image 대상	7,422
S3 URL 치환 완료	6,975
외부 image URL 잔존	0
source_image_url 보존	6,975
원천 이미지 없음	447
이미지 다운로드/업로드 실패	0

5.2 이미지 버킷 검증

이미지 버킷 검증 결과, 2026-06-29 13:00Z 이후 생성된 images/KR/ 객체는 6,975개다. 총 크기는 2,009,551,566 bytes, 약 2.01 GB다.

6. Review 산출물 상태

6.1 Review queue 현황

review/ 산출물은 queue 기준과 entity type 기준으로 나누어, 검토 대상의 성격을 빠르게 구분할 수 있게 정리했다.

review/ prefix에는 1,202건이 분리되어 있다.

Review queue	Count
source_review	1,184
location_review	18
classification_review	1

6.2 Entity type 현황

Review queue count 합계가 1,202보다 1건 많은 이유는 1개 record가 복수 queue를 가진 것으로 판단한다.

Review record 자체는 1,202건이다.

Entity type	Review records
excluded	1,184
attraction	16
festival	2
합계	1,202

7. 남은 리스크와 후속 작업

7.1 후속 작업 목록

남은 항목은 전처리 실패가 아니라 검토 정책과 보강 기준을 확정해야 하는 작업이다.

항목	현재 상태	후속 작업
Wikipedia missing 59건	검토 필요	suffix normalize 적용 여부와 raw 후보가 없는 11개 key의 보강 여부 결정
No source image 447건	검토 필요	이미지 없는 상태 허용 또는 대체 이미지 수집 정책 결정
Review record 1,202건	검토 필요	source_review location_review classification_review별 분류

8. 결론

8.1 전처리 완료 결론

결론: 20260629 KR 데이터 전처리는 완료됐다. 2026-06-29 raw detail 240개는 모두 kr-pipeline-transform에서 성공 처리됐고, passed/ 기준 8,010개 산출 item이 생성됐다.

8.2 품질 검토 우선순위

현재 남은 작업은 전처리 품질 검토다. 우선순위는 Wikipedia missing 59건의 suffix normalization 및 raw 후보 보강 여부 결정, 원천 이미지가 없는 447건의 허용 정책 결정, review record 1,202건의 queue별 분류다.

9. 변경 이력

9.1 변경 이력

버전	날짜	작성자	변경 내용
v1.0	2026-06-29	Codex	KR 20260629 상세 데이터 전처리 결과를 전처리 보고서 범위로 재정리하고 PDF 가독성을 보정